

Süßigkeiten und Webapps zur Vermittlung von KI-Grundlagen aus einer datenbasierten Perspektive

Experimente und Intuition

Ziele

- Motivation unserer Fortbildung
 - Anwender*innen benötigen Grundlagenwissen, um Modelloutput einzuordnen.
 - Formale Notation, explizites Lehren von Algorithmen und technische sowie datenschutzbezogene Abhängigkeiten schaffen eine Einstiegsschwelle.
 - Black Box Begriff verschleiert, was tatsächlich alles verstanden werden kann.
 - Die Relation zwischen Daten und Modell wird selten umfassend dargestellt.
 - Bilderkennung ist überschaubar, Text nicht. Grundlagen gelten jedoch 1:1.
- Experimente:
 - Was kann das jeweilige Modell eigentlich?
 - Beziehung Modellverhalten und Trainingsdaten
 - Menschliche Sicht vs. Maschine
 - Eigene Anwendungen und Spiele
 - Optional: fragwürdige Anwendungsfälle


Motivation: Mama



Hallo Mama, ich habe gerade mit der Ärztin gesprochen und sie hat mir gesagt dass sie sich bei dir melden wird wenn sie wieder da ist und dann können wir ja mal schauen ob wir uns vielleicht doch noch mal sehen können und dann können wir ja mal schauen wie es mit dem Treffen aussieht und dann können wir ja noch mal schreiben oder telefonieren oder so ich hab dich lieb und bis bald tschüss und ich hab dich ganz doll lieb und ich hoffe wir sehen uns bald wieder und ich freu mich schon auf dich und ich freu mir schon auf morgen wenn wir uns wieder sehen und ich hoffe das du auch noch ein bisschen Zeit für mich hast und ich hoffe du hast auch ein bisschen Zeit für dich und ich hoffe du hast dich auch ein bisschen erholt und ich hoffe du hast einen schönen Tag und ich hoffe du hast heute einen schönen Tag mit deiner Familie und ich hoffe das wir uns bald wieder sehen und ich hoffe wir sehen uns bald wieder und ich freu mich schon sehr auf dich und

- Kontext inhaltlich und technisch
- Fehler inhaltlich und grammatikalisch
- Next token/word prediction: sinnvoll, passend oder einfach was im Schnitt am wahrscheinlichsten ist


Motivation: Der Weg zur Süßigkeiten-Bilderkennung



Motivation: Süßigkeiten-Bilderkennung



Motivation: Süßigkeiten-Bilderkennung



Repräsentativ?
Labellingfehler?
Unausgeglichenheit?
Bias?



Objekterkennung

Aufgabe 1: Funktionalität und Fehler

- Beleuchtungsstärke, mehrere Objekte gleichzeitig, (teil)verdeckte Objekte, Entfernung/Größe, Drehung
- Was wird nicht erkannt?
- Was bedeutet "Sicherheit"

Aufgabe 2: Sicherheit

- Variiert die Sicherheit im Slider im Slider und experimentiert erneut



<https://shorturl.at/dLmvv>

Objekterkennung

 Hintergrund  Person  Fahrrad  Auto  Motorrad 

Flugzeug

 Bus  Zug  LKW  Boot  Ampel  Feuerhydrant

 Stoppschild  Parkuhr  Bank  Vogel  Katze  Hund 

Pferd

 Schaf  Kuh  Elefant  Bär  Zebra  Giraffe  Rucksack

 Regenschirm  Handtasche  Krawatte  Koffer  Frisbee 

Ski

 Snowboard  Sportball  Drachen  Baseballschläger

 Baseballhandschuh  Skateboard  Surfbrett  Tennisschläger

 Flasche  Weinglas  Tasse  Gabel  Besteck  Löffel

 Schüssel  Banane  Apfel  Sandwich  Orange  Brokkoli

 Karotte  Hotdog  Pizza  Donut  Kuchen  Stuhl  Sofa

 Topfpflanze  Bett  Esstisch  Toilette  Fernseher 

Objekterkennung

What is COCO?



COCO is a large-scale object detection, segmentation, and captioning dataset. COCO has several features:

- ✓ Object segmentation
- ✓ Recognition in context
- ✓ Superpixel stuff segmentation
- ✓ 330K images (>200K labeled)
- ✓ 1.5 million object instances
- ✓ 80 object categories
- ✓ 91 stuff categories
- ✓ 5 captions per image
- ✓ 250,000 people with keypoints



person, bicycle, car, motorcycle, airplane, bus, train, truck, boat, traffic light, fire hydrant, stop sign, parking meter, bench, bird, cat, dog, horse, sheep, cow, elephant, bear, zebra, giraffe, backpack, umbrella, handbag, tie, suitcase, frisbee, skis, snowboard, sports ball, kite, baseball bat, baseball glove, skateboard, surfboard, tennis racket, bottle, wine glass, cp, fork, knife, spoon, bowl, banana, apple, sandwich, orange, broccoli, carrot, hot dog, pizza, donut, cake, chair, couch, potted plant, bed, dining table, toilet, tv, laptop, mouse, remote, keyboard, cell phone, microwave, oven, toaster, sink, refrigerator, book, clock, vase, scissors, teddy bear, hair drier, toothbrush

Model Card - Open Data

Modell



Age and Gender Recognition Model

The age and gender recognition model is a multitask network, which employs a feature extraction layer, an age regression layer and a gender classifier. The model has a size of roughly 420kb and the feature extractor employs a tinier but very similar architecture to Xception.

Daten



This model has been trained and tested on the following databases with an 80/20 train/test split each: UTK, FGNET, Chalearn, Wiki, IMDB*, CACD*, MegaAge, MegaAge-Asian. The * indicates, that these databases have been algorithmically cleaned up, since the initial databases are very noisy.

Total Test Results

Total MAE (Mean Age Error): 4.54

Total Gender Accuracy: 95%

Test results for each database

The - indicates, that there are no gender labels available for these databases.

Database	UTK	FGNET	Chalearn	Wiki	IMDB*	CACD*	MegaAge	MegaAge-Asian
MAE	5.25	4.23	6.24	6.54	3.63	3.20	6.23	4.21
Gender Accuracy	0.93	-	0.94	0.95	-	0.97	-	-

Benchmarks auf
Datensätzen
(Train/Test)



Test results for different age category groups

Age Range	0 - 3	4 - 8	9 - 18	19 - 28	29 - 40	41 - 60	60 - 80	80+
MAE	1.52	3.06	4.82	4.99	5.43	4.94	6.17	9.91
Gender Accuracy	0.69	0.80	0.88	0.96	0.97	0.97	0.96	0.9

Model Card - GPT-6

In this card

Change log

Safety Overview: GPT-6 Astra

Model Data and Training

Internal Deployment of Astra

Model Safety

> Safe Completions

Vision

Robustness

2. Model Data and Training

Daten?

Like OpenAI’s other models, GPT-6 Astra was trained on diverse datasets and filtered through our data processing pipeline, including to reduce personal information.

Evaluation	GPT-6 Astra	GPT-5.6 Sor ^[2]	Claude Fable 5.1	Claude Fable 5	Claude Opus 5	Gemini 3.8 Flash
ARC-AGI-3	98.6% ^[1]	7.8%	-	-	30.2% (high)	-
FrontierMath Tier 4 (v2)	97.6%	83.0%	87.8%	87.8%	73.2%	-
Agents' Last Exam	59.3%	52.7%	-	48.7% (xhigh)	52.7%	-
AutomationBench	41.4%	18.1%	31.4%	17.4%	26.9%	-
BenchCAD	95.9%	83.3%	84.3% ^[5]	67.5% ^[5]	82.1% ^[5]	-
DeepSWE v1.1	74.1%	70.8%	67.4%	69.9%	68.8%	73.7%
Terminal-Bench Science 0.1	64.6%	22.4%	52.6%	24.7%	29.0%	-
GPQA Diamond	96.0%	94.6%	93.7%	92.6%	93.2%	95.3%
GeneBench Pro	39.0%	28.7%	-	-	-	-
MedChemBench (internal)	49.7%	47.4%	-	-	-	-
HealthBench Professional (length-adjusted)	63.4%	60.5%	56.6% ^[9]	60.9%	[57.5%]	52.1%
ExploitBench	100.0%	78.5%	-	-	70%	-
SRE-Bench (four attempts)	99.2%	68.7%	-	-	-	-
Auto-review circumvention (internal; lower is better)	0%	0.29%	-	-	-	-


g. These models are trained to think
esponding to the user. Through training,
I recognize their mistakes. Reasoning
helping them act in line with our safety
attempts to bypass safety rules.

sions evaluated at that time. The
flect later versions of those models, and

Unabhängige und
“unabhängige”
Benchmarks

Demo: Süßigkeiten-Bilderkennung

Beziehung zwischen Trainingsdaten und Modellverhalten



Adversarial Examples: Menschliche Sicht vs. Maschine

Aufgabe 1: Adversarial Examples


- “Feindliche” Beispiele, welche die Modellvorhersage beeinflussen.
- Hier am Beispiel eines Age-Gender-Prediction Modells (Verzeihung, Funktionalität nur männlich / weiblich)
- Wie müsste ich mein Aussehen verändern, um von einem Menschen als das andere Geschlecht erkannt zu werden?
- Wie kann ich ein Bild von mir verändern, dass dieses Bilderkennungsmodell die Vorhersage ändert?

-
- Testet das Modell unter 
-
- Geht anschließend auf 
-

- Nehmt ein Bild von euch auf
- Wählt das Ziel-Geschlecht aus, wohin euer Bild manipuliert werden soll
- Verändert den Faktor, mit dem das berechnete Störbild auf euer Foto addiert wird (1.2 = 1.2%)
- Wie viel braucht es? Erkennt man etwas?

Ziel: weiblich ▼ 

Faktor - 1.2 + 




<https://shorturl.at/n1TQI>

Eigene Anwendung und Spiele

Aufgabe 1: Training

- Das Trainingsprogramm ist Google Teachable Machine nachempfunden. Im Anschluss kann das Modell ohne Export in Anwendungen eingebunden werden
- Nehmt für verschiedene Klassen Bilder auf (Knopf gedrückt lassen = mehrere Bilder)
 - Beispiel: rechte Hand hochhalten, linke Hand hochhalten
 - Funktioniert das bereits zuverlässig? Führt eine Hintergrund/Rest Klasse ein, um ein Gegenbeispiel für die gewollten Klassen zu haben
 - Funktioniert es besser wenn man farbige Gegenstände in den Händen halt
 - Person A macht alle Bilder einer Klasse a, Person B die andere Klasse b. Wird bei Person A vor der Kamera anschließend Klasse b erkannt



<https://shorturl.at/cy1Dd>

Aufgabe 2: Anwendung

- Testet eure Modelle als Controller für das Snake Spiel
- Generiert eine eigene Anwendung (API Key wird von mir geteilt)


Fragwürdige Anwendungsfälle

Sollten diese Anwendungsfälle existieren?


Wo können sie seriös benötigt werden?

Welche Diskussionspunkte entstehen?

Akzeptanz/Vertrauen in Technologie?




Age-Gender (von vorhin)
<https://shorturl.at/n1TQI>



Emotionen
<https://shorturl.at/0qZSo>

Fortbildung - Vorabversion



https://ddihd.github.io/fortbildung_preview/index.html